

KWJA：汎用言語モデルに基づく 日本語解析器

植田 暢大 大村 和正 児玉 貴志


清丸 寛一 村脇 有吾 河原 大輔 黒橋 禎夫

京都大学 / 早稲田大学


2022/9/29 第253回自然言語処理研究会@京都大学

はじめに：end-to-end vs 言語解析（1/2）

機械翻訳をはじめ、NLPタスクでは end-to-end モデルが主流



機械翻訳 [Vaswani+, 2017]



対話応答生成 [Roller+, 2021]

はじめに：end-to-end vs 言語解析（2/2）

しかし本質的に試行錯誤を要するタスクでは依然言語解析が重要

- ・ 例）情報分析、因果関係分析




因果関係グラフ [清丸ら, 2020] における因果関係の深堀り

はじめに：従来の言語解析ツール

これまで解析タスクごとにツールが個別に開発されてきたが：

- 利用が困難：ツールごとに使い方を理解する必要
- メンテナンスが困難：ツールごとに実装を管理・修正する必要



KWJA：汎用言語モデルに基づく日本語解析器

汎用言語モデルを基盤とし、単体であらゆる言語解析を実行する日本語の統合的言語解析器KWJA (Kyoto-Waseda Japanese Analyzer) を開発

- 利用が容易：ツール単体であらゆる言語解析が可能
- メンテナンスが容易：汎用言語モデルにより共通した実装を実現




関連研究：spaCy (GiNZA)

- Universal Dependencies (UD) に基づく多言語統合的基礎解析器
 - 日本語モデルは日本語 UD コーパスから学習可能な言語解析（形態素解析、構文解析、固有表現認識）を実行
 - ▶ KWJA は基礎解析の前処理であるタイポ修正から高レイヤの言語解析である述語項構造解析・談話関係解析までサポート（ここまで統合的に解析を行う解析器は存在しない）
- *GiNZAでは形態素解析に Sudachi を使用
- すべての言語で統一的な方法で解析器を訓練
 - ▶ 日本語特有の現象（省略等）への対応は困難


KWJAの解析フロー

- ・ 計算コスト削減のため可能な限りマルチタスクで解析を共通化
- ・ 共通化できない部分はパイプライン処理
 1. 入力誤り訂正：誤字・脱字などを訂正
 2. 文字レベル解析：文字列を正規化しつつ単語列に分割
 3. 単語レベル解析：その他単語に基づく処理




KWJAが実行する言語解析

処理単位	タスク	定式化
文字	入力誤り訂正	系列ラベリング
	分かち書き	系列ラベリング
	単語正規化	系列ラベリング
単語 (サブワード)	形態素解析	系列ラベリング
	固有表現認識	系列ラベリング
	言語素性付与	系列ラベリング
	構文解析	単語選択
	述語項構造解析	単語選択
	橋渡し照応解析	単語選択
	共参照解析	単語選択
	談話関係解析	単語間関係分類



固有表現抽出（系列ラベリング）の例




構文解析（単語選択）の例

入力誤り訂正

- タスク：テキスト中の入力誤りを検知・修正
 - 例) 誤字訂正：人□知能 → 人工知能
 - 脱字訂正：有力ある → 有力である
 - 衍字訂正：お世話に~~に~~なって → お世話になって

I:x	直前にxを挿入
K	そのまま
D	削除
R:x	xで置換


- 解き方：文字単位系列ラベリング



文字単位タスク：分かち書き・単語正規化


- **分かち書き**：文字列を単語（形態素）列に分割
- **単語正規化**：非標準表記と連濁を正規化
 - 例）非標準表記：びみよ——→びみよう
連濁：上海ガニ→上海カニ
- 解き方：文字単位系列ラベリング

B	単語開始位置
I	単語中間位置
K	そのまま
D	削除
P	長音符を母音に置換
V	濁音を清音に置換
⋮	⋮




単語単位タスク：形態素解析（分かち書き）

- ・タスク：単語（サブワード）に対し、品詞・品詞細分類・活用型・活用形・原形・読み・意味情報を付与
- ・解き方：サブワード単位系列ラベリング




単語単位タスク：固有表現認識

- タスク：文中の固有表現を認識
 - 例) 気象庁によると一日午後四時ごろ、京都市で地震が発生した。
ORGANIZATION DATE TIME LOCATION
- 解き方：サブワード単位系列ラベリング + CRF




単語単位タスク：言語素性付与

- タスク：単語および基本句に言語素性を付与
 - 単語素性：基本句主辞、基本句-区切、文節-区切、用言表記先頭・末尾
 - 基本句素性：用言、体言、状態述語、動態述語、節-主辞、節-区切、...
- 解き方：サブワード単位系列ラベリング




単語単位タスク：構文解析

- ・タスク：単語間の係り受けおよび係り受けタイプを解析
 - ・係り受けタイプ：D（通常の係り受け）、P（並列）、A（同格）、I（部分並列）
- ・解き方：サブワード単位単語選択 [柴田ら, 2019] + 単語間関係分類



単語単位タスク：述語項構造・橋渡し照応・共参照解析

- 述語項構造解析：述語に対し、ガ・ヲ・ニ・ガ 2 格の項を特定
- 橋渡し照応解析：名詞に対し、必須的なノ格の項を特定
- 共参照解析：名詞に対し、同一の実体を指す名詞を特定
- 解き方：サブワード単位単語選択 [Ueda+, 2020]



単語単位タスク：談話関係解析


- ・タスク：節間の談話関係を認識

・例) 風が吹けば、桶屋が儲かる。風呂屋も儲かる。



- ・解き方：サブワード単位単語間関係分類

・ラベル：原因・理由、目的、条件、根拠、対比、逆接、談話関係なし




実験設定


- 事前学習モデル
 - 文字単位：RoBERTa LARGE WWM
(<https://huggingface.co/ku-nlp/roberta-large-japanese-char-wwm>)
 - 単語単位：RoBERTa LARGE
(<https://huggingface.co/nlp-waseda/roberta-large-japanese-seq512>)
- データセット（3種類を混合して訓練、個別に評価）
 - 京都大学テキストコーパス（新聞）：4万文
 - 京都大学ウェブ文書リードコーパス（ウェブ）：1.5万文
 - 注釈付き不満買取センターコーパス（ユーザ投稿）：1,282文
- マルチタスク学習で fine-tuning

実験結果 (1/2)


入力誤り訂正




分かち書き



単語正規化 (F値)



形態素解析 (F値)




- 入力誤り訂正はより適合率を重視
- 分かち書きはJuman++に匹敵
- 単語正規化は訓練データ不足により新聞・ウェブコーパスの精度がほぼゼロ
- 形態素解析は読み推定に改善の余地あり

実験結果 (2/2)

- 構文解析はBERTに基づく先行研究を上回る性能
- 述語項構造解析、談話関係解析は改善の余地あり

単語単位タスク解析精度
(構文解析：LAS、その他：F値)



解析例

イベントグラフ[斎藤ら, 2018]を用いることで述語項構造や談話関係などを可視化可能

現在の自然言語処理ではend-to-endモデルが主流である。
しかし、情報分析や因果関係分析を支援するには言語解析が依然として重要である。

[surf] 現在の自然言語処理ではend-to-endモデルが主流である。

[pas] 主流/主流:判, モデル/モデル:ガ

[features] 時制:非過去

基本句素性・述語項構造

[surf] [著者が] 情報分析や因果関係分析を支援するには

[pas] 支援/支援:動, [著者]:ガ, 分析/分析:ヲ

[features] 時制:非過去

談:目的

談話関係

[surf] しかし、言語解析が依然として重要である。


[pas] 重要である/重要である:形, 解析/解析:ガ

[features] 時制:非過去

言語素性

議論：シングルタスクとの比較

- マルチタスク学習においてはタスク全体での最適値が個々のタスクの最適値とは限らない
- 精度が低い述語項構造解析・橋渡し照応解析・共参照解析・談話関係解析についてシングルタスク学習で実験



談話関係解析

20ポイント近く向上



解析器ではシングルタスク
モデルを提供

議論：解析速度の検証

実験設定

- 解析データ：日本語 CC-100 [Wenzek+, 2020] から1,000文を無作為に抽出
- 計算資源：NVIDIA Tesla V100 32GB GPU 1枚
- バッチサイズ：128（入力誤り訂正）、512（文字単位解析）、2（単語単位解析）


KWJA と Juman++ & KNPとの比較

- KWJA：6.4分（1秒あたり2.6文）
- Juman++ & KNP：3.2分（1秒あたり5.2文）

議論：入力誤り訂正の閾値とその他議論

入力誤り訂正においては訂正操作の閾値の調整により、適合率を重視した保守的な運用が可能

- 例) 入力 : 観覧席の人をTVに映ることもある
閾値0.0 : 観覧席の人がTVに移ることもある
閾値0.8 : 観覧席の人がTVに映ることもある



その他議論

- 分かち書きにおけるユーザ辞書の利用
- 単語正規化におけるラベル不均衡
- 固有表現認識・言語素性付与におけるカテゴリごとの精度

KWJAを使うには？

- コマンドラインから

```
$ pip install --user kwja  
$ kwja --text “今日は晴れた。散歩に行こう。” # 結果をKNPフォーマットで出力  
$ kwja --file raw.txt > analyzed.knp
```

- Python から

```
$ pip install rhoknp
```

```
from rhoknp import KWJA  
kwja = KWJA()  
analyzed_document = kwja.apply(“今日は晴れた。散歩に行こう。”)
```

 <https://github.com/ku-nlp/kwja>

 <https://github.com/ku-nlp/rhoknp>

おわりに

- 統合的日本語解析器KWJAを開発・一般公開
- 統一的なアーキテクチャの採用により、新たなタスクにもデータセットさえあれば容易に適用可能
- Version 2.0 にむけて
 - ユーザ辞書の追加による柔軟な分かち書き
 - マルチタスク学習における談話関係解析の改善
 - 周辺の事例への対応
 - 部分的なアノテーション